

Predicción de Riesgo de Desnutrición Infantil en Ecuador

Prueba técnica – Especialista en Inteligencia Artificial

Paul Cárdenas-Delgado

31 de mayo de 2026

1. Resumen

Este informe presenta una solución de clasificación supervisada para predecir riesgo de desnutrición en niños menores de dos años, utilizando el dataset sintético del reto *Ecuador Infant Malnutrition Risk Prediction [MCD]* de Kaggle. La variable objetivo fue `alerta_desnutricion`, donde 1 representa riesgo y 0 ausencia de alerta. El desarrollo se estructuró bajo CRISP-DM, complementado con prácticas de reproducibilidad y validación propias de MLOps. El flujo incluyó análisis exploratorio, control de calidad de datos, tratamiento de valores faltantes e inconsistencias, ingeniería de características, comparación de modelos, análisis de desbalance, explicabilidad y evaluación de riesgos. Aunque la métrica oficial del reto es Accuracy, también se evaluaron Precision, Recall, F1-score y ROC-AUC debido al desbalance observado. El mejor desempeño interno fue obtenido por una Regresión Logística sobre el Escenario B de tratamiento de datos, con un ROC-AUC de 0.6589, superando o igualando a modelos más complejos como Random Forest, XGBoost y CatBoost. Esto sugiere que la señal predictiva disponible es moderada y principalmente capturable mediante relaciones lineales.

2. Comprensión del problema

El reto consiste en desarrollar un modelo de clasificación binaria capaz de identificar niños/as menores de dos años con posible riesgo de desnutrición a partir de variables demográficas, contextuales y antropométricas. Dado su enfoque en salud pública, la evaluación de la solución no se limita al desempeño predictivo, sino que también considera aspectos de explicabilidad, reproducibilidad y uso responsable de la inteligencia artificial.

El conjunto de datos incluye variables como edad, sexo, región, nivel educativo de la madre, peso y talla, además de la variable objetivo `alerta_desnutricion`. Asimismo, incorpora valores faltantes, inconsistencias y observaciones atípicas que simulan desafíos frecuentes en escenarios reales de análisis de datos.

3. Metodología

Se adoptó CRISP-DM como marco metodológico para estructurar el desarrollo del proyecto en las fases de comprensión del problema, comprensión de los datos, preparación de datos, modelado, evaluación y propuesta de despliegue. Este enfoque facilita la trazabilidad y justificación de las decisiones tomadas durante todo el proceso.

De manera complementaria, se incorporaron principios de MLOps orientados a garantizar reproducibilidad y robustez, incluyendo la separación entre entrenamiento y validación para evitar fuga de información, el uso de pipelines de preprocesamiento reproducibles, la comparación sistemática de escenarios y modelos, y el registro de métricas para sustentar la selección final. Asimismo, se consideraron aspectos de monitoreo, mantenimiento y gobernanza para una eventual implementación institucional.

El flujo de trabajo seguido comprendió: (1) configuración inicial, (2) carga y revisión de datos, (3) análisis exploratorio, (4) preparación e ingeniería de características, (5) construcción de modelos base y avanzados, y (6) selección y evaluación del modelo final.

4. Análisis exploratorio de datos

El conjunto de entrenamiento contiene 70,000 registros y seis variables predictoras originales (`edad_meses`, `sexo`, `region`, `nivel_educacion_madre`, `peso_kg`, `talla_cm`), además de la variable objetivo `alerta_desnutricion`. Se observó un marcado desbalance de clases, con aproximadamente 90 % de registros sin alerta y 10 % con alerta, lo que motivó el uso de métricas complementarias a Accuracy para la evaluación de modelos.

Durante el análisis exploratorio se identificaron valores faltantes, principalmente en peso y talla, así como inconsistencias en la edad (valores negativos o superiores a 24 meses) y observaciones antropométricas extremas para el grupo etario analizado. Estas inconsistencias fueron reemplazadas por NaN en lugar de eliminar los registros, permitiendo conservar información potencialmente útil en otras variables. La imputación se realizó posteriormente dentro de los pipelines de modelado utilizando únicamente el conjunto de entrenamiento para evitar fuga de información.

En las variables categóricas, `sexo` mostró distribuciones similares entre clases y una contribución predictiva limitada. Por el contrario, `region` y `nivel_educacion_madre` evidenciaron diferencias relevantes entre categorías. En particular, la región Amazónica presentó una menor prevalencia de alerta, mientras que la categoría *Sin escolaridad* mostró un comportamiento atípico. No obstante, estos patrones fueron interpretados con cautela, ya que pueden reflejar variables no observadas o características propias de la generación de los datos y no necesariamente relaciones causales directas.

Se identificaron 3921 registros con edad menor a 0 meses, 3163 con edad superior a 24 meses, 3469 pesos faltantes, 7049 tallas faltantes y 673 pesos superiores a 30 kg. Las inconsistencias de edad fueron reemplazadas por valores faltantes, los datos ausentes se imputaron mediante la mediana y los pesos extremos fueron evaluados mediante dos escenarios de tratamiento.

5. Preparación de datos e ingeniería de características

Con el fin de fortalecer el análisis de calidad de datos, las variables antropométricas fueron contrastadas con los Estándares de Crecimiento Infantil de la Organización Mundial de la Salud (OMS) para niños de 0 a 24 meses. Las distribuciones de peso y talla se compararon con los rangos de referencia para identificar valores implausibles, posibles errores de registro y observaciones extremas. En lugar de eliminar automáticamente estos casos, se incorporaron variables indicadoras que permiten capturar desviaciones respecto a los rangos de referencia, preservando información potencialmente relevante para el modelo [1].

A partir de este proceso se generaron banderas binarias para representar valores faltantes e inconsistencias `peso_missing`, `talla_missing`, `edad_missing`, `edad_fuera_rango`, `peso_fuera_rango_oms`, `talla_fuera_rango_oms`, `peso_extremo`, así como variables derivadas que capturan relaciones antropométricas relevantes, incluyendo el índice de masa corporal `imc`) y las razones `peso_talla_ratio`: relación peso/talla, `peso_edad_ratio`: relación peso/edad, `talla_edad_ratio`: relación talla/edad.

Para el tratamiento de pesos extremos se evaluaron dos escenarios: (A) eliminación de registros atípicos y (B) corrección asumiendo un posible error de punto decimal. El Escenario B fue seleccionado como configuración principal debido a que conservó la totalidad de los registros y presentó un desempeño igual o ligeramente superior en los modelos evaluados.

El preprocesamiento se implementó mediante *pipelines* de `scikit-learn`. Las variables numéricas fueron imputadas con la mediana y escaladas mediante `RobustScaler`, mientras que las variables categóricas se imputaron con la categoría más frecuente y se codificaron mediante `OneHotEncoder`. Todos los transformadores fueron ajustados exclusivamente sobre el conjunto de entrenamiento para evitar fuga de información.

Finalmente, se evaluaron estrategias de balanceo mediante SMOTE y UnderSampling. Aunque estas técnicas modificaron algunas métricas de clasificación, no produjeron mejoras consistentes en ROC-AUC ni F1-score y, en varios casos, redujeron la capacidad de generalización observada durante la validación. Por esta razón, el modelo final se construyó sin aplicar balanceo artificial de clases.

6. Modelado y experimentación

El desarrollo del modelo siguió un enfoque experimental iterativo. En lugar de seleccionar un algoritmo a priori, se compararon múltiples familias de modelos y diferentes estrategias de preparación de datos para identificar cuáles aportaban mayor capacidad predictiva.

Aunque la competencia utiliza Accuracy como métrica principal, esta medida resulta insuficiente debido al desbalance de clases observado (aproximadamente 90 % clase 0 y 10 % clase 1).

Por esta razón se utilizaron adicionalmente las siguientes métricas: Accuracy, Precision, Recall, F1-score, ROC-AUC.

Se prestó especial atención al Recall de la clase positiva, ya que en un escenario de salud pública resulta más costoso no detectar un caso potencial de riesgo que generar una alerta adicional.

Se implementaron los siguientes modelos: Dummy Classifier (línea base), Regresión Logística, Árbol de Decisión, Random Forest, Random Forest con SMOTE, XGBoost, CatBoost, Regresión Logística con UnderSampling, Regresión Logística con variables polinómicas, Versiones optimizadas mediante búsqueda de hiperparámetros. Todos los modelos fueron entrenados utilizando la misma partición entrenamiento-validación para garantizar comparabilidad.

La Tabla 1 resume los principales resultados obtenidos durante la experimentación.

Tabla 1: Resumen de resultados obtenidos

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression (Escenario B)	0.420	0.140	0.935	0.244	0.659
Decision Tree (Escenario B)	0.412	0.140	0.947	0.244	0.655
Random Forest	0.427	0.140	0.915	0.243	0.650
Random Forest + SMOTE	0.826	0.147	0.154	0.151	0.630
XGBoost	0.521	0.140	0.733	0.235	0.652
CatBoost	0.900	0.000	0.000	0.000	0.651
Logistic Regression + UnderSampling	0.421	0.140	0.930	0.243	0.658
Logistic Regression + Polynomial Features	0.417	0.140	0.938	0.244	0.653

Los resultados muestran que los modelos más complejos no lograron superar consistentemente a la Regresión Logística. Incluso después de incorporar técnicas de balanceo y optimización de hiperparámetros, las mejoras observadas fueron marginales.

Este comportamiento sugiere que la capacidad predictiva del conjunto de variables es relativamente limitada. En consecuencia, incrementar la complejidad del modelo no produjo ganancias relevantes en capacidad discriminativa.

7. Selección del modelo final

Durante el desarrollo se evaluaron múltiples algoritmos, estrategias de limpieza, técnicas de balanceo y configuraciones de hiperparámetros. Sin embargo, ningún modelo complejo superó de forma consistente a la Regresión Logística entrenada sobre el Escenario B. Aunque la métrica oficial de la competencia es Accuracy, la selección final no se basó únicamente en dicha medida, ya que el problema corresponde a un contexto de salud pública con costos de error asimétricos. En este escenario, un falso positivo implica una evaluación adicional, mientras que un falso negativo puede significar no detectar oportunamente a un niño en posible riesgo. Por ello, se otorgó mayor relevancia a Recall, F1-score y ROC-AUC, seleccionando el modelo que ofreció el mejor equilibrio entre capacidad discriminativa, interpretabilidad y utilidad potencial en un entorno institucional real.

La Tabla 2 resume los resultados del modelo seleccionado.

Tabla 2: Desempeño del modelo final seleccionado

Accuracy	Precision	Recall	F1-score	ROC-AUC
0.420	0.140	0.935	0.244	0.659

Dado que la competencia evalúa las predicciones mediante Accuracy, se realizó un análisis adicional para identificar el umbral que maximizaba esta métrica. El mejor resultado se obtuvo con un umbral cercano a 0.71, alcanzando una Accuracy aproximada del 90 %. Sin embargo, esta configuración provocó una reducción drástica en la capacidad del modelo para detectar casos de riesgo, clasificando prácticamente todos los registros como pertenecientes a la clase mayoritaria. Como consecuencia, el Recall de la clase positiva se aproximó a cero y más de 1400 casos de riesgo fueron clasificados incorrectamente como casos sin alerta.

Este comportamiento evidencia una limitación conocida de Accuracy en problemas con clases desbalanceadas: es posible obtener valores elevados de la métrica sacrificando la detección de la clase minoritaria. Considerando que el objetivo del sistema es apoyar la identificación temprana de posibles casos de desnutrición, se descartó el umbral óptimo para Accuracy y se mantuvo una configuración orientada a maximizar la sensibilidad del modelo y reducir el riesgo de omitir casos potencialmente vulnerables.

Una vez seleccionado el modelo final, este fue reentrenado utilizando el conjunto completo de entrenamiento disponible y posteriormente aplicado sobre el conjunto de prueba proporcionado por Kaggle. Las predicciones fueron exportadas siguiendo exactamente el formato especificado por la competencia:

8. Conclusiones

Este trabajo desarrolló una solución completa de aprendizaje automático para la identificación de riesgo de desnutrición infantil utilizando datos sintéticos inspirados en escenarios reales de salud pública. Durante el proceso se realizaron actividades de análisis exploratorio, control de calidad de datos, tratamiento de valores faltantes, detección de inconsistencias, ingeniería de características, evaluación comparativa de modelos, análisis de explicabilidad y diseño de una propuesta de despliegue.

Los resultados muestran que la información disponible permite distinguir parcialmente los casos de riesgo, alcanzando valores de ROC-AUC cercanos a 0.66. Sin embargo, la capacidad predictiva observada sugiere que existen factores relevantes no capturados en las variables disponibles. Las variables con mayor contribución fueron la región geográfica, el nivel educativo de la madre y los indicadores antropométricos derivados de peso, talla y edad. Asimismo, se observó que la variable sexo tiene una contribución prácticamente nula, mientras que la eliminación de región y educación de la madre provoca una reducción importante del desempeño. Finalmente, la Regresión Logística fue seleccionada como modelo final debido a que alcanzó el mejor equilibrio entre desempeño predictivo, interpretabilidad, estabilidad y facilidad de implementación.

9. Declaración de Herramientas Utilizadas

Durante el desarrollo de la solución se utilizaron herramientas de inteligencia artificial generativa como apoyo para tareas de redacción técnica, revisión de documentación, organización del informe y discusión de alternativas metodológicas. En particular, se emplearon modelos de lenguaje de gran escala (LLM) para mejorar la claridad de algunos textos, documentar decisiones técnicas y explorar posibles enfoques de modelado.

No obstante, todas las etapas críticas del proyecto, incluyendo el análisis exploratorio de datos, la definición de estrategias de limpieza, la ingeniería de características, la implementación de los modelos, la selección de métricas, la validación experimental y la interpretación de resultados, fueron realizadas, verificadas y validadas por el autor. Las recomendaciones generadas por herramientas de IA fueron consideradas únicamente como apoyo y no fueron incorporadas sin revisión técnica previa.

Asimismo, todo el código ejecutado, los experimentos realizados, las métricas reportadas y las conclusiones presentadas en este documento son reproducibles a partir de los artefactos entregados y pueden ser auditados mediante el notebook y los archivos de resultados incluidos en la entrega.

Referencias

- [1] World Health Organization, *WHO Child Growth Standards: Length/Height-for-Age, Weight-for-Age, Weight-for-Length, Weight-for-Height and Body Mass Index-for-Age*. Geneva, Switzerland: World Health Organization, 2006.